

CalZSAD: Chọn ngưỡng tự động cho phát hiện bất thường zero-shot dựa trên CLIP với kiểm soát tỷ lệ dương tính giả

Nguyễn Dương, 250101084, Đinh Thị Thu Hiệp, 250101085, và Nguyễn Minh Chiến, 250101080

Abstract—Phát hiện bất thường (anomaly detection) nhằm nhận diện mẫu lệch khỏi phân phối bình thường, đóng vai trò quan trọng trong kiểm tra chất lượng công nghiệp và phân tích hình ảnh y tế. Các phương pháp CLIP-based zero-shot gần đây, đặc biệt AA-CLIP, đạt AUROC trên 90% trên nhiều benchmark nhưng chỉ sinh ra điểm bất thường liên tục mà không cung cấp ngưỡng quyết định, khiến việc triển khai thực tế không khả thi. Ba trở ngại chính gồm: điểm bất thường dịch chuyển giữa các lớp sản phẩm, pixel-AUROC bị lạc quan do mất cân bằng cực đoan (trên 99% pixel là bình thường), và ngưỡng từ miền nguồn không chuyển được sang miền đích. Nhóm áp dụng CalZSAD, một module hậu xử lý nhẹ gắn trên backbone AA-CLIP đã đóng băng, gồm ba thành phần: tín hiệu top-1% pixel, chuẩn hóa robust theo lớp (median + MAD), và chọn ngưỡng conformal chỉ cần 20 ảnh bình thường mỗi lớp. Thử nghiệm trên sáu bộ dữ liệu (3 công nghiệp, 3 y tế) cho thấy CalZSAD duy trì FPR từ 0.94 đến 5.74% quanh mức mục tiêu 5%, đạt F1 chỉ cách oracle 5 đến 9 điểm. Ở mức pixel, Dice tại FAR 1% sát oracle với pixel-FPR quanh 1%.

Index Terms—Phát hiện bất thường zero-shot, CLIP, AA-CLIP, conformal prediction, chọn ngưỡng, kiểm soát FPR.

I. GIỚI THIỆU

Phát hiện bất thường nhằm nhận diện các mẫu lệch khỏi phân phối bình thường, ứng dụng rộng rãi từ kiểm tra chất lượng sản xuất [9] đến sàng lọc hình ảnh y tế [12]. Vì mẫu lỗi hiếm và đa dạng, các phương pháp giám sát đòi hỏi bộ dữ liệu lỗi lớn là không thực tế; do đó các hướng tiếp cận unsupervised và zero-shot chỉ học từ dữ liệu bình thường được quan tâm nhiều.

Mô hình vision-language CLIP [2] mở ra hướng zero-shot anomaly detection (ZSAD) phát hiện lỗi trên lớp sản phẩm hoàn toàn mới mà không cần dữ liệu huấn luyện riêng. WinCLIP [3] dùng prompt thủ công kết hợp multi-scale windowing. AnomalyCLIP [4] học prompt không phụ thuộc tên lớp. AdaCLIP [5] kết hợp prompt tĩnh và động. AA-CLIP [1] (CVPR 2025) tách ngữ nghĩa bình thường/bất thường trong không gian ngôn ngữ trước khi căn chỉnh đặc trưng ảnh, đạt AUROC cao nhất trên nhiều benchmark. Tuy nhiên, tất cả các phương pháp này chỉ sinh ra điểm bất thường liên tục mà không cung cấp ngưỡng quyết định. Trong thực tế, hệ thống cần ra quyết định nhị phân “bình thường” hay “bất thường”, và quyết định này phụ thuộc rất lớn vào ngưỡng.

Nhóm áp dụng CalZSAD, một module hậu xử lý nhẹ gắn trên backbone AA-CLIP đã đóng băng, gồm ba thành phần: (i) thay điểm ảnh gốc bằng trung bình top-1% pixel cao nhất từ bản đồ bất thường; (ii) chuẩn hóa robust theo lớp bằng median và MAD; (iii) chọn ngưỡng conformal chỉ cần $K=20$ ảnh bình thường mỗi lớp, đảm bảo $FPR \leq \alpha$ mà không cần giả định phân phối. Pipeline này không huấn luyện lại backbone và áp dụng được cho mọi mô hình CLIP-ZSAD.

Đóng góp chính gồm: (1) đề xuất CalZSAD biến điểm bất thường thô từ AA-CLIP thành quyết định nhị phân sẵn sàng triển khai với FPR được kiểm soát; (2) đánh giá toàn diện trên 6 bộ dữ liệu (công nghiệp và y tế) với cả metric ranking (AUROC, AP, AUPRO, AUPIMO) lẫn metric vận hành (F1, Recall, FPR, Dice), chỉ ra khoảng cách giữa AUROC cao và khả năng triển khai thực tế.

II. CÔNG TRÌNH LIÊN QUAN

Các phương pháp CLIP-ZSAD hiện tại (WinCLIP [3], AnomalyCLIP [4], AdaCLIP [5], AA-CLIP [1]) đều tập trung tối ưu chất lượng ranking (AUROC) nhưng không giải quyết bài toán chọn ngưỡng. AA-CLIP là phương pháp mạnh nhất nhờ tách ngữ nghĩa bất thường trong không gian ngôn ngữ, nhưng vẫn chỉ sinh ra điểm liên tục.

Về đánh giá, pixel-AUROC bị lạc quan mạnh khi dữ liệu mất cân bằng (trên 99% pixel bình thường) [6]. AUPIMO [7] đánh giá overlap tại FPR thấp, cho thước đo sát thực tế hơn.

Về chọn ngưỡng, phương pháp Otsu không ổn định khi phân phối chồng lấn; Peaks-Over-Threshold (POT) dựa trên lý thuyết giá trị cực trị nhưng nhạy với ngoại lai. Conformal prediction [8] đảm bảo $FPR \leq \alpha$ với mẫu hữu hạn mà không cần giả định phân phối. Điểm khác biệt chính của CalZSAD so với các phương pháp trên là kết hợp chuẩn hóa robust theo lớp trước khi áp dụng conformal, giúp ngưỡng so sánh được giữa các lớp và miền dữ liệu khác nhau.

III. PHƯƠNG PHÁP ĐỀ XUẤT

CalZSAD là module hậu xử lý gắn sau backbone AA-CLIP đã đóng băng, hoạt động qua hai pha: *pha hiệu chuẩn* (một lần, dùng $K=20$ ảnh bình thường mỗi lớp) và *pha suy luận* (mỗi ảnh test). Hình 1 minh họa pipeline.




Fig. 1. Pipeline CalZSAD. *Pha hiệu chuẩn (trên)*: K ảnh bình thường đi qua backbone CLIP-ZSAD đóng băng, module tín hiệu top-tail trích $q = \text{Mean}(\text{Top-}\rho\%(M))$, chuẩn hóa theo lớp ($z = \mathcal{N}_c(q)$) và đặt ngưỡng conformal $t_{c,\alpha}$. *Pha suy luận (dưới)*: ảnh test đi qua cùng pipeline, so sánh $z(x)$ với ngưỡng để ra quyết định. Không huấn luyện lại backbone.

A. Phát biểu bài toán

Gọi f_θ là mô hình AA-CLIP đóng băng. Với ảnh đầu vào x , mô hình sinh bản đồ bất thường pixel $M(x) \in \mathbb{R}^{H \times W}$ và điểm ảnh $s(x) \in \mathbb{R}$. Với mỗi lớp c , ta có K ảnh bình thường $X_c^n = \{x_1^n, \dots, x_K^n\}$ (không có ảnh lỗi, không có annotation pixel). Mục tiêu: chọn ngưỡng $t_{c,\alpha}$ sao cho $\text{FPR}_c(t_{c,\alpha}) \lesssim \alpha$ (mặc định $\alpha = 0.05$).

B. Tín hiệu top-1% pixel

Thay vì dùng điểm ảnh gốc $s(x)$, CalZSAD trích tín hiệu phân biệt hơn từ bản đồ pixel:

$$q(x) = \text{mean}(\{M(i, j) : M(i, j) \geq Q_{99\%}(M)\}) \quad (1)$$

với $Q_{99\%}(M)$ là percentile thứ 99 của bản đồ. Tín hiệu này bắt vùng bất thường cục bộ mà ít bị ảnh hưởng bởi nhiễu so với giá trị max đơn lẻ.

C. Chuẩn hóa robust theo lớp

Để loại bỏ dịch chuyển thang điểm giữa các lớp, $q(x)$ được chuẩn hóa theo thống kê robust từ K ảnh hiệu chuẩn:

$$z(x) = \frac{q(x) - \mu_c}{\sigma_c} \quad (2)$$

trong đó $\mu_c = \text{median}(\{q(x_i^n)\}_{i=1}^K)$ và $\sigma_c = 1.4826 \times \text{median}(|q_{\text{left}} - \mu_c|)$ là MAD tính trên nửa trái phân phối. Sau chuẩn hóa, ảnh bình thường ở mọi lớp đều tập trung quanh 0 với độ phân tán đơn vị.

D. Chọn ngưỡng conformal

Với K điểm hiệu chuẩn đã chuẩn hóa $R_c = \{r_{(1)}, \dots, r_{(K)}\}$ sắp tăng, ngưỡng conformal là:

$$t_{c,\alpha} = r_{(m)}, \quad m = \min\{[(K+1)(1-\alpha)], K\} \quad (3)$$

Ảnh test được phân loại bất thường nếu $z(x) > t_{c,\alpha}$. Với $K=20, \alpha=0.05$: $m = \lceil 21 \times 0.95 \rceil = 20$, ngưỡng là max của 20 điểm hiệu chuẩn, FPR lý thuyết $\approx 4.76\%$ [8].

Ở mức pixel, ngưỡng được tính bằng quantile thực nghiệm trên toàn bộ pixel từ K ảnh bình thường tại pixel-FAR $\beta=1\%$.

IV. THỰC NGHIỆM

A. Thiết lập

Backbone: AA-CLIP [1] (CVPR 2025), huấn luyện trên VisA, áp dụng zero-shot lên tất cả miền đích.

Dữ liệu: 6 bộ thuộc 2 miền: *Công nghiệp* gồm MVTEC-AD [9] (15 lớp), BTAD [10] (3 lớp), MPDD [11] (6 lớp); *Y tế* gồm Brain MRI, Liver CT, Retina OCT từ BMAD [12].

Giao thức: Metric tính per-class rồi macro-average. CalZSAD dùng $K=20$ ảnh bình thường mỗi lớp. Kết quả trung bình qua 8 seed (image) và 3 seed (pixel). FPR mục tiêu $\alpha=5\%$; pixel-FAR mục tiêu $\beta=1\%$.

B. Kết quả mức ảnh

Bảng I trình bày kết quả mức ảnh. Cột “Ref.” là AUROC từ paper AA-CLIP gốc [1]; cột “Ours” là kết quả reproduce của nhóm (chênh lệch do khác data split và preprocessing).

CalZSAD kiểm soát FPR sát mức mục tiêu 5% trên cả 6 bộ (0.94% đến 5.74%). Với công nghiệp, F1 đạt 83.70 (MVTec),

TABLE I

KẾT QUẢ MỨC ẢNH TRÊN BACKBONE AA-CLIP. “REF.” LÀ IMG-AUROC TỪ PAPER GỐC, “OURS” LÀ KẾT QUẢ REPRODUCE. CÁC CỘT CÒN LẠI LÀ METRIC VẬN HÀNH TỪ CALZSAD TẠI FPR $\approx$ 5% ($K=20$, NGƯỠNG CONFORMAL, TÍN HIỆU TOP-1%).

Miền	Dataset	AUROC (Ref.)	AUROC (Ours)	Δ	AP	FPR (%)	Recall (%)	F1 (%)	Oracle F1 (%)
Công nghiệp	BTAD	94.8	93.98	−0.82	93.09	5.74	64.47	74.26	79.69
	MPDD	75.1	73.06	−2.04	78.49	3.79	30.27	46.21	49.62
	MVTec-AD	90.5	84.92	−5.58	92.94	4.41	72.74	83.70	86.47
Y tế	Brain	80.2	58.40	−21.80	86.30	3.43	21.41	34.26	42.92
	Liver	69.7	57.16	−12.54	53.74	0.94	2.16	4.09	13.55
	Retina	82.7	71.49	−11.21	65.50	5.02	51.54	63.81	71.94

74.26 (BTAD), 46.21 (MPDD), chỉ cách oracle 3 đến 6 điểm. Với y tế, Retina đạt F1 63.81 (oracle 71.94); Brain và Liver thấp hơn nhưng oracle cũng thấp (42.92 và 13.55), cho thấy hạn chế nằm ở backbone chứ không phải chọn ngưỡng.

C. Kết quả mức pixel

Bảng II trình bày kết quả mức pixel.

Pixel-AUROC reproduce sát paper gốc (chênh ± 0.75). Điểm đáng chú ý: tất cả 6 bộ có px-AUROC trên 92% nhưng px-AP chỉ từ 9.96 (Liver) đến 63.54 (Retina), khoảng cách 30 đến 88 điểm. Hiện tượng “AUROC lạc quan” [6] này xảy ra do mất cân bằng cực đoan ở mức pixel, cho thấy cần metric bổ sung như Dice hoặc AUPIMO [7]. CalZSAD đạt pixel-FPR sát 1% (0.87 đến 1.09%), Retina đạt Dice cao nhất (50.11).

V. KẾT LUẬN

Nhóm áp dụng CalZSAD lên backbone AA-CLIP để biến điểm bất thường thô thành quyết định nhị phân với FPR được kiểm soát, chỉ cần 20 ảnh bình thường mỗi lớp và không cần mẫu lỗi. Thực nghiệm trên 6 bộ dữ liệu cho thấy FPR sát mức mục tiêu 5%, F1 cách oracle 5 đến 9 điểm (công nghiệp), và pixel-FPR sát 1%. Đánh giá cũng chỉ ra pixel-AUROC bị lạc quan mạnh (chênh 30 đến 80 điểm so với px-AP) và miền y tế khó hơn đáng kể do hạn chế của backbone CLIP trên ảnh y tế.

REFERENCES

- [1] W. Ma *et al.*, “AA-CLIP: Enhancing zero-shot anomaly detection via anomaly-aware CLIP,” *CVPR*, pp. 4744–4754, 2025.
- [2] A. Radford *et al.*, “Learning transferable visual models from natural language supervision,” *ICML*, pp. 8748–8763, 2021.
- [3] J. Jeong *et al.*, “WinCLIP: Zero/few-shot anomaly classification and segmentation,” *CVPR*, pp. 19606–19616, 2023.
- [4] Q. Zhou *et al.*, “AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection,” *ICLR*, 2024.
- [5] Y. Cao *et al.*, “AdaCLIP: Adapting CLIP with hybrid learnable prompts for zero-shot anomaly detection,” *ECCV*, pp. 55–72, 2024.
- [6] T. Saito and M. Rehmsmeier, “The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets,” *PLoS ONE*, vol. 10, no. 3, 2015.
- [7] J. P. C. Bertoldo *et al.*, “AUPIMO: Redefining visual anomaly detection benchmarks with high speed and low tolerance,” *BMVC*, 2024.
- [8] A. N. Angelopoulos and S. Bates, “A gentle introduction to conformal prediction and distribution-free uncertainty quantification,” *Found. Trends Mach. Learn.*, vol. 16, no. 4, 2023.

- [9] P. Bergmann *et al.*, “MVTec AD: A comprehensive real-world dataset for unsupervised anomaly detection,” *CVPR*, pp. 9592–9600, 2019.
- [10] P. Mishra *et al.*, “VT-ADL: A vision transformer network for image anomaly detection and localization,” *ISIE*, pp. 1–6, 2021.
- [11] S. Jezek *et al.*, “Deep learning-based defect detection of metal parts,” *ICUMT*, pp. 66–71, 2021.
- [12] J. Bao *et al.*, “BMAD: Benchmarks for medical anomaly detection,” *arXiv:2306.11876*, 2023.

TABLE II
KẾT QUẢ MỨC PIXEL TRÊN BACKBONE AA-CLIP. DICE@FAR1% LÀ HỆ SỐ DICE KHI BINARIZE BẢN ĐỒ BẤT THƯỜNG TẠI NGƯỠNG PIXEL-FAR 1%.

Miền	Dataset	px-AUROC (Ref.)	px-AUROC (Ours)	Δ	px-AP	AUPRO	AUPIMO	Dice @FAR1%	px-FPR (%)
Công nghiệp	BTAD	97.0	97.41	+0.41	55.66	67.38	75.95	24.30	1.01
	MPDD	96.7	96.55	−0.15	25.49	81.38	42.25	22.15	0.87
	MVTec-AD	91.9	92.55	+0.65	48.97	74.29	78.12	35.12	0.89
Y tế	Brain	95.5	95.21	−0.29	39.21	74.68	35.46	31.11	1.09
	Liver	97.8	97.71	−0.09	9.96	64.39	47.48	23.54	0.96
	Retina	95.5	96.25	+0.75	63.54	74.90	47.94	50.11	0.93